

Detección de alucinaciones en LLM mediante la dinámica estructural de los grafos de atención

Nicolás Schiaffino Mellado & Gabriel Venegas Ortiz

PUC & UTFSM

IIC 3641 Aprendizaje Basado en Grafos
Prof. Marcelo Mendoza



Outline

- 1 Problema
- 2 Técnicas a utilizar
- 3 Datos
- 4 elementos diferenciadores
- 5 Plan de Actividades
- 6 Entregables
- 7 Referencias

Alucinaciones en LLMs



El impacto de los Large Language Models (LLMs) se expande rápidamente en dominios críticos como la salud, la educación y el desarrollo de software. Sin embargo, esta adopción masiva eclipsa una vulnerabilidad fundamental: las **alucinaciones**.



Este fenómeno puede llevar a resultados inesperados y potencialmente perjudiciales, resaltando la necesidad de una investigación más profunda hacia la detección y mitigación de estas alucinaciones.

- Se entrenará un **Variational Auto Encoder (VAE)** para el grafo obtenido en base a la matriz de activaciones y las activaciones de cada token (nodo) en una capa determinada. Esto con el fin de obtener una representación estructural latente (**Z**) de cada grafo.
- Una vez se obtengan todas las representaciones estructurales latentes a lo largo de todas las capas, se entrenará un MLP para identificar anomalías en la estructura considerando la capa anterior y posterior.

Generación del Dataset

El dataset con el que se trabajará será una recolección del estado interno de *Llama-3.2-1B* (activaciones y atenciones **por cada capa**).

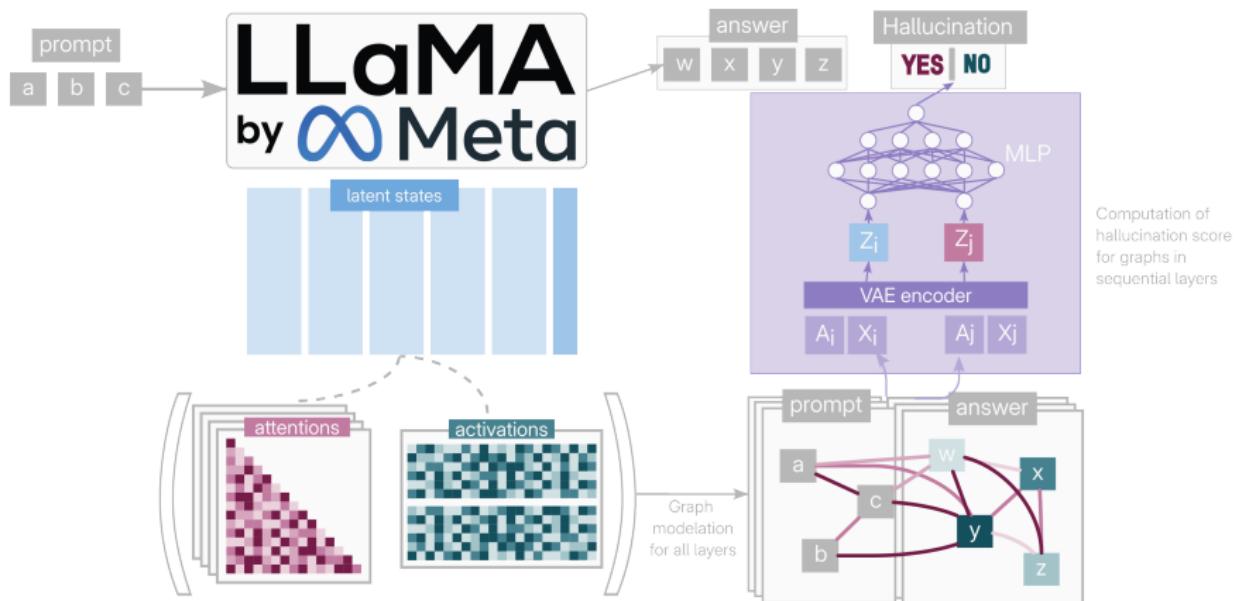
Los inputs para recuperar cada estado interno constan de las preguntas presentes en el dataset *TruthfulQA*.

Diferencias con otros enfoques

Los elementos a grandes rasgos son 3 y se compara con el State of the Art en detección de alucinaciones en LLMs.

- ① HaloScope [2] introduce la noción de una diferencia geométrica en el espacio latente entre contenido no alucinado y si alucinado. No obstante, trabaja con una versión **estática** del espacio latente.
- ② CHARM [3] propone un modelamiento de las activaciones y atenciones en un grafo pero **colapsa toda la arquitectura a un solo grafo** promediando la información entre capas.
- ③ HalluShift [1] realiza la detección basándose en las distancias entre las distribuciones de la matriz de atención a través de las capas. Sin embargo, **no captura información estructural**.

Graphical Abstract



Actividades Avance de proyecto

Fase	Actividades Principales
Avance	<ol style="list-style-type: none">1. Generar las respuestas del Llama-1B para <i>TruthfulQA</i>.2. Implementar el script de "autopsia" para extraer los <i>hidden states</i> y <i>scores</i> de atención $A_{l,h}$ de las capas L.
Proyecto	<ol style="list-style-type: none">3. Procesar y guardar en disco el <i>dataset</i> final de secuencias de grafos $\{G_l\}$.4. Implementar el <i>dataloader</i> que carga las secuencias de grafos desde el disco.5. Implementar <i>VAE</i> para el entrenamiento sobre los grafos G_l.

Actividades Entrega Final

Fase	Actividades Principales
Entrega	<ol style="list-style-type: none">1. Entrenar el VAE de forma no supervisada sobre el <i>dataset</i> mixto hasta la convergencia (minimizando $L_{recon} + L_{KL}$)2. Implementar los <i>scripts</i> de <i>scoring de alucinaciones</i> (MLP) sobre la secuencia de z_l (representaciones estructurales latentes)
Final	<ol style="list-style-type: none">3. Implementar HaloScope & HalluShift para conocer cuáles resultados obtienen en Llama-3.2-1B4. Ejecutar la evaluación en el dataset de <i>test</i> y generar gráficos comparativos.

Entregables

Fase	¿Qué se entrega?
Avance	<p>Para las actividades 1., 2. y 3. se entregará un dataset subido a alguna plataforma en la nube (por ej. <i>Zenodo</i>) junto con un instructivo especificando cómo fue generado el dataset.</p> <p>Para la actividades 4. y 5. se entregará un enlace al repositorio <i>GitHub</i> con las implementaciones de los códigos y las correspondientes instrucciones para su ejecución.</p>
Final	<p>Se entregará un enlace al repositorio de <i>github</i> extendiendo las instrucciones</p> <p>Los resultados obtenidos tendrán en consideración la replicabilidad de los experimentos y se detallará en el repositorio.</p>

De todas formas, para ambas entregas se cumplirá adicionalmente con comentar el avance y mencionar todas las modificaciones realizadas.

Referencias

- [1] S. Dasgupta, S. Nath, A. Basu, P. Shamsolmoali, and S. Das. Hallushift: Measuring distribution shifts towards hallucination detection in llms, 2025. URL <https://arxiv.org/abs/2504.09482>.
- [2] X. Du, C. Xiao, and Y. Li. Haloscope: Harnessing unlabeled llm generations for hallucination detection. In A. Globerson, L. Mackey, D. Belgrave, A. Fan, U. Paquet, J. Tomczak, and C. Zhang, editors, *Advances in Neural Information Processing Systems*, volume 37, pages 102948–102972. Curran Associates, Inc., 2024. URL https://proceedings.neurips.cc/paper_files/paper/2024/file/ba92705991cfbbcedc26e27e833ebbae-Paper-Conference.pdf.
- [3] F. Frasca, G. Bar-Shalom, Y. Ziser, and H. Maron. Neural message-passing on attention graphs for hallucination detection, 2025. URL <https://arxiv.org/abs/2509.24770>.